

LAPORAN AKHIR
PROYEK PENGANTI UAS

Mata Kuliah Kecerdasan Buatan
Semester Genap 2025/2026

**SecondPrice: Prediksi Harga Jual Barang Bekas dengan
Graph Neural Network**

Subjudul: Implementasi GraphSAGE / GAT untuk Prediksi Harga Produk Bekas

Disusun oleh:

Ibnu Zaky Fauzi	NPM. 2306161870
Maharaka Fadillah	NPM. 2306225520
Nugroho Ulil Abshar	NPM. 2306229310
Samih Bassam	NPM. 2306250623

Dosen Pengampu:

Muhammad Firdaus Syawaludin Lubis, S.T., M.T., Ph.D.

DEPARTEMEN TEKNIK ELEKTRO
FAKULTAS TEKNIK
UNIVERSITAS INDONESIA
MEI 2026

LEMBAR PERNYATAAN ORISINALITAS

Kami yang bertandatangan di bawah ini menyatakan bahwa laporan ini, beserta seluruh isinya (termasuk Sub-bab IV.x masing-masing anggota dan berkas metadata.json yang merupakan bagian tidak terpisahkan), adalah hasil karya kelompok kami sendiri. Setiap kutipan, kode, atau gambar yang berasal dari sumber lain telah disitasi dengan benar. Penggunaan AI assistant telah dideklarasikan secara jujur pada Sub-bab IV.x.2.



(Ibnu Zaky Fauzi)
NPM. 2306161870



(Maharaka Fadillah)
NPM. 2306225520



(Nugroho Ulil Abshar)
NPM. 2306229310



(Samih Bassam)
NPM. 2306250623

ABSTRAK

Proyek ini membangun sistem prediksi harga otomatis berbasis Graph Neural Network (GNN) untuk menentukan nilai jual wajar barang bekas pada platform e-commerce tanpa bergantung pada fitur gambar. Dengan memanfaatkan Mercari Price Suggestion Dataset yang berisi lebih dari 1,4 juta entri data, informasi transaksional diabstraksikan menjadi sebuah heterogeneous graph yang menghubungkan node produk dengan relasi struktural kategori berlapis dan merek. Fitur tekstual nama serta deskripsi produk diekstraksi menggunakan Sentence-Transformers untuk menginisialisasi state awal representasi node. Pemodelan dilakukan dengan menerapkan varian induktif GraphSAGE dan Graph Attention Network (GAT) melalui framework PyTorch Geometric untuk memfasilitasi proses message passing lintas entitas relasional. Evaluasi performa model dilakukan secara komparatif mengandalkan metrik Root Mean Squared Logarithmic Error (RMSLE) dan Mean Absolute Error (MAE) terhadap baseline konvensional berupa perpaduan TF-IDF dengan Ridge Regression serta arsitektur XGBoost tabular. Hasil evaluasi eksperimen awal menunjukkan bahwa penangkapan relasi topologi graph mampu meningkatkan stabilitas prediksi harga pada barang berkategori spesifik sekaligus mereduksi bias penentuan harga intuitif secara signifikan.

Kata kunci: Graph Neural Network, Prediksi Harga, Barang Bekas, GraphSAGE, Mercari Dataset

DAFTAR ISI

1	PENDAHULUAN & DEFINISI MASALAH	7
1.1	Topik yang Dipilih	7
1.2	Rumusan Masalah	7
1.3	Tujuan Proyek	7
1.4	Ruang Lingkup & Batasan	8
2	PENDEKATAN AI	9
2.1	Tinjauan Pustaka (Related Work)	9
2.2	Landasan Teori Model yang Dipilih	9
2.3	Justifikasi Ilmiah Pemilihan Pendekatan AI	11
2.4	Block Diagram Sistem End-to-End	11
2.5	Flowchart Program	12
3	IMPLEMENTASI & HASIL EKSPERIMEN	14
3.1	Dataset & Pra-pemrosesan	14
3.2	Konfigurasi Eksperimen	15
3.3	Metrik Evaluasi	15
3.4	Hasil Kuantitatif	16
3.5	Analisis Hyperparameter Tuning	16
3.6	Hasil Kualitatif & Error Analysis	17
3.7	Pembahasan	21
4	PEMBAGIAN TUGAS & DEKLARASI KONTRIBUSI INDIVIDUAL	23
4.1	Ibnu Zaky Fauzi – NPM. 2306161870	23
4.1.1	Komponen yang Dikerjakan	23
4.1.2	Pernyataan Penggunaan AI Assistant	23
4.2	Nugroho Ulil Abshar – NPM. 2306229310	23
4.2.1	Komponen yang Dikerjakan	23
4.2.2	Pernyataan Penggunaan AI Assistant	24
4.3	Samih Bassam – NPM. 2306250623	24
4.3.1	Komponen yang Dikerjakan	24

4.3.2	Pernyataan Penggunaan AI Assistant	24
4.4	Maharaka Fadillah – NPM. 2306225520	25
4.4.1	Komponen yang Dikerjakan	25
4.4.2	Pernyataan Penggunaan AI Assistant	25
5	KESIMPULAN & PEKERJAAN LANJUTAN	26
5.1	Kesimpulan	26
5.2	Klaim Bonus Skor	26
5.3	Pekerjaan Lanjutan (<i>Future Work</i>)	26
A	Berkas Metadata Proyek (JSON)	29
B	Tautan Repositori & Sumber	31
C	Research Participation Consent Form (<i>Informed Consent</i>)	32

DAFTAR GAMBAR

2.1	Arsitektur Graph Neural Network (GNN)	10
2.2	Block diagram sistem yang diusulkan	12
2.3	Flowchart program training dan inference	13
3.1	Kurva konvergensi pelatihan GraphSAGE dan GAT	17
3.2	Uji AI melalui Website (Kasus 1)	18
3.3	Uji AI melalui Website (Kasus 2)	19
3.4	Uji AI melalui Website (Kasus 3)	20

DAFTAR TABEL

2.1	Ringkasan tinjauan pustaka	9
3.1	Pembagian dataset	14
3.2	Hyperparameter eksperimen	15
3.3	Hasil kuantitatif model	16
3.4	Matriks Hipotesis Kegagalan dan Strategi Mitigasi	21

BAB 1

PENDAHULUAN & DEFINISI MASALAH

1.1 Topik yang Dipilih

Proyek ini memilih topik **Graph Neural Network (GNN)** yang berfokus pada pemecahan masalah regresi dalam penentuan estimasi kontekstual nilai aset digital. Alasan pemilihan topik ini didasarkan pada karakteristik data marketplace barang bekas di Indonesia (seperti OLX, Carousell, dan Facebook Marketplace) yang memiliki ketergantungan relasional yang sangat kuat antar entitas produk, struktur hierarki kategori, dan kesamaan merek dagang. Pendekatan machine learning konvensional kerap gagal menangkap keterkaitan non-linear ini karena mengasumsikan setiap baris data bersifat independen (IID).

Melalui keahlian tim dalam rekayasa data dan ketertarikan mendalam pada representasi struktur graf terarah, pemanfaatan framework GNN dinilai sebagai solusi paling progresif untuk mengatasi fluktuasi penentuan harga sepihak yang sering tidak konsisten. Keberadaan Mercari Dataset berskala besar di repositori publik memberikan urgensi domain yang matang untuk menguji sejauh mana performa arsitektur deep learning berbasis graf mampu mengasimilasi fitur tekstual dan topologi pasar secara simultan demi melahirkan keputusan harga yang adil bagi penjual maupun pembeli.

1.2 Rumusan Masalah

- RM1.** Bagaimana merepresentasikan data transaksional marketplace barang bekas ke dalam bentuk struktur graf heterogen (*heterogeneous graph*) yang optimal?
- RM2.** Bagaimana mengimplementasikan varian arsitektur GraphSAGE dan Graph Attention Network (GAT) untuk menyelesaikan tugas prediksi regresi harga jual?
- RM3.** Bagaimana performa akurasi model berbasis Graph Neural Network jika dibandingkan dengan model baseline konvensional seperti TF-IDF + Ridge Regression dan XGBoost?
- RM4.** Sejauh mana pengaruh eksploitasi relasi topologi antar node tetangga (*neighborhood*) berkontribusi dalam meminimalkan galat prediksi harga produk?

1.3 Tujuan Proyek

- T1.** Membangun rancangan representasi graf heterogen yang merekatkan entitas barang, dekomposisi tingkat kategori, serta merek dari dataset e-commerce.
- T2.** Menerapkan algoritma agregasi pesan (*message passing*) menggunakan arsitektur GraphSAGE dan GAT memanfaatkan library PyTorch Geometric.

- T3.** Mengevaluasi dan membandingkan akurasi performa prediksi regresi model usulan terhadap baseline menggunakan metrik MAE, RMSE, RMSLE, dan R^2 score.
- T4.** Menganalisis efek bias struktural serta kontribusi pembobotan fitur relasional terhadap fluktuasi nilai prediksi harga jual barang bekas.

1.4 Ruang Lingkup & Batasan

Implementasi proyek pengganti UAS ini dibatasi oleh ruang lingkup dan batasan-batasan teknis sebagai berikut:

- **Domain Data:** Eksperimen hanya menggunakan data tekstual dan metadata produk yang bersumber dari Mercari Price Suggestion Dataset di Kaggle, serta tidak melibatkan analisis fitur gambar produk.
- **Varian Model:** Evaluasi arsitektur GNN dibatasi pada varian GraphSAGE (*inductive learning*) dan Graph Attention Network (GAT), dengan model baseline berupa Ridge Regression (TF-IDF) dan XGBoost standar.
- **Skala Pelatihan:** Guna efisiensi komputasi, pelatihan model menggunakan 200.000 baris pertama dari keseluruhan entri dataset dengan pembagian 80:10:10 (random seed 42).
- **Batasan Eksperimen:** Proyek ini tidak melakukan optimasi pencarian arsitektur selapis demi selapis (*layer-by-layer neural architecture search*) secara masif dan tidak mengevaluasi performa model pada distribusi data luar (*out-of-distribution data*) di luar ekosistem dataset Mercari.

BAB 2

PENDEKATAN AI

2.1 Tinjauan Pustaka (Related Work)

Berikut adalah ringkasan literatur utama yang dijadikan landasan komparatif dan konseptual bagi pengembangan arsitektur graf pada proyek ini:

Tabel 2.1: Ringkasan tinjauan pustaka

Penulis (Th.)	Metode	Dataset	Hasil	Keterbatasan
Hamilton dkk. (2017) [1]	Varian GraphSAGE dengan pendekatan <i>inductive representation learning</i> .	Reddit, Protein-Protein Interaction	Berhasil men-generate embedding berkualitas tinggi untuk node baru tanpa retraining ulang graf.	Belum menguji efektivitas arsitektur pada struktur regresi nilai komersial nominal.
Veličković dkk. (2018) [2]	Graph Attention Networks (GAT) memanfaatkan masked self-attention layers .	CORA, Cite-seer, Pubmed Citation graph	Mencapai akurasi state-of-the-art melalui pemberian bobot dinamis pada node tetangga.	Biaya komputasi melambung tinggi seiring bertambahnya densitas keterhubungan edge.
Zhu (2023) [3]	E-Commerce Recommendation berbasis Graph Neural Network.	Alisports	Sukses mengabstraksikan relasi produk e-commerce tanpa data personal sensitif.	Fokus terbatas pada tugas klasifikasi rekomendasi produk, bukan regresi harga produk.

Posisi Proyek: Berbeda dengan literatur [1] dan [2] yang menguji GNN pada domain sitasi umum, serta literatur [3] yang berorientasi pada klasifikasi sistem rekomendasi, proyek *SecondPrice* memosisikan GNN secara khusus untuk memecahkan masalah regresi estimasi nilai moneter (prediksi harga) pada graf heterogen komersial dengan mengawinkan ekstraksi NLP lightweight embeddings bersama informasi topologi marketplace tanpa ketergantungan pada data histori pengguna.


2.2 Landasan Teori Model yang Dipilih

Model utama yang diimplementasikan bersandar pada arsitektur graf heterogen yang memanfaatkan mekanisme message passing update . Operasi agregasi fitur pada neighborhood di layer GraphSAGE mengikuti formulasi matematis kunci sebagai berikut:

$$h_{\mathcal{N}(v)}^{(k)} \leftarrow \text{AGGREGATE}_k \left(\{h_u^{(k-1)}, \forall u \in \mathcal{N}(v)\} \right) \quad (2.1)$$

$$h_v^{(k)} \leftarrow \sigma \left(W^{(k)} \cdot \left[h_v^{(k-1)} \parallel h_{\mathcal{N}(v)}^{(k)} \right] \right) \quad (2.2)$$

di mana $h_v^{(k)}$ mewakili vektor representasi (*embedding*) dari node v pada lapisan ke- k , $\mathcal{N}(v)$ menyatakan himpunan node tetangga yang terhubung langsung dengan node v , AGGREGATE_k melambangkan fungsi agregasi struktural (seperti fungsi rata-rata atau pooling), $W^{(k)}$ merupakan matriks bobot transformasi linier yang dapat dilatih, $\parallel$ mengekspresikan operasi konkatenasi antar representasi vektor, dan σ menyatakan fungsi aktivasi non-linear (ReLU).



Gambar 2.1: Arsitektur Graph Neural Network (GNN)


2.3 Justifikasi Ilmiah Pemilihan Pendekatan AI

Pemilihan arsitektur GNN (GraphSAGE / GAT) didasarkan pada pertimbangan ilmiah mendalam mengenai topologi data marketplace:

1. Eksploitasi Ketergantungan Struktural: Data produk bekas memiliki keterkaitan inheren. Sepasang barang dengan kondisi berbeda akan memiliki konvergensi harga yang dipengaruhi oleh kesamaan entitas brand atau sub-kategori. GNN memfasilitasi transfer informasi ini lewat edge connectivity, hal yang diabaikan oleh model tabular murni.
2. Trade-off Kemampuan Induktif vs Transduktif: Ekosistem platform e-commerce bersifat sangat dinamis; ribuan produk diunggah setiap jamnya. Pilihan jatuh pada GraphSAGE karena sifatnya yang induktif, memungkinkan inferensi instan terhadap node produk baru lewat parameter agregasi yang telah terlatih tanpa memicu degradasi performa ataupun kebutuhan rekonstruksi matriks laplacian graf secara utuh.
3. Fleksibilitas Mekanisme Attention: Penggunaan varian GAT memberikan keunggulan alokasi bobot dinamis via koefisien attention, sehingga model mampu secara cerdas memprioritaskan apakah faktor kemiripan merek atau kedekatan deskripsi tekstual yang lebih berhak mendominasi penentuan harga suatu sub-kategori barang tertentu.

2.4 Block Diagram Sistem End-to-End


Rangkaian pemrosesan data, arsitektur penyusunan graf, hingga pembentukan keluaran nilai prediksi harga diilustrasikan melalui diagram blok di bawah ini:



Gambar 2.2: Block diagram sistem yang diusulkan

2.5 Flowchart Program

Alur siklus runtime program yang mencakup percabangan fase pelatihan (training loop) dan jalur inferensi aplikasi (inference pipeline) akan direpresentasikan menggunakan notasi flowchart pada bagian dokumentasi eksperimen final.



Gambar 2.3: Flowchart program training dan inference

BAB 3

IMPLEMENTASI & HASIL EKSPERIMEN

3.1 Dataset & Pra-pemrosesan

Dataset yang digunakan dalam penelitian ini adalah *Mercari Price Suggestion Challenge* yang dipublikasikan secara terbuka di platform Kaggle pada tahun 2018. Dataset ini diterbitkan oleh Mercari, Inc. di bawah lisensi *Competition Rules* Kaggle dan diperbolehkan digunakan untuk keperluan riset non-komersial.

File utama yang digunakan adalah `train.tsv`, sebuah *tab-separated values* yang memuat 1.482.535 listing produk bekas dengan delapan atribut, yaitu: `train_id` (identifikasi unik), `name` (nama produk), `item_condition_id` (kondisi barang berskala 1–5), `category_name` (hierarki kategori tiga level), `brand_name` (merek produk), `price` (harga jual dalam dolar AS), `shipping` (indikator biaya kirim ditanggung penjual), dan `item_description` (deskripsi teks bebas). Terdapat nilai hilang pada tiga kolom: `brand_name` ($\approx 42,7\%$), `category_name` ($\approx 0,4\%$), dan `item_description` ($< 0,01\%$).

Tahap pra-pemrosesan dilakukan dengan langkah-langkah berikut. Pertama, diambil 200.000 baris pertama dari `train.tsv` sebagai subset kerja karena keterbatasan memori. Baris dengan `price = 0` kemudian dihapus sehingga tersisa 199.894 sampel valid dengan rentang harga \$3,00–\$1.909,00 dan median \$17,00. Nilai hilang pada `brand_name` diisi dengan "No Brand", `category_name` dengan "Other/Other/Other", dan `item_description` dengan string kosong. Kolom berformat `Level1/Level2/Level3` selanjutnya dipecah menjadi tiga kolom terpisah (`cat_1`, `cat_2`, `cat_3`). Teks pada kolom `name` dan `item_description` masing-masing di-*lowercase*, dihapus karakter non-alfanumerik, dinormalisasi spasinya, lalu digabung menjadi `text_combined`. Terakhir, kolom target $\log_{\text{price}} = \log_e(\text{price} + 1)$ ditambahkan untuk menstabilkan distribusi harga yang *right-skewed*.

Dataset bersih sebanyak 199.894 sampel dibagi dengan rasio 80:10:10 menggunakan **random seed 42** seperti ditunjukkan pada Tabel 3.1.

Tabel 3.1: Pembagian dataset

Subset	Jumlah Sampel	Rasio (%)
Training	159.915	80
Validation	19.989	10
Test	19.990	10
Total	199.894	100

3.2 Konfigurasi Eksperimen

Eksperimen dijalankan pada lingkungan *Google Colab* dengan akselerator GPU NVIDIA T4 (15 GB VRAM), RAM sistem 12 GB. Durasi pelatihan GraphSAGE dan GAT masing-masing sekitar 90 menit per eksperimen. Seluruh eksperimen menggunakan **random seed 42** untuk menjamin reproduibilitas.

Penelitian ini melatih empat model: dua model *baseline* (TF-IDF + Ridge Regression dan XGBoost) serta dua model GNN (GraphSAGE dan GAT). Tabel 3.2 merangkum seluruh rincian konfigurasi *hyperparameter* optimal yang digunakan selama fase pelatihan model utama berbasis graf (*GraphSAGE* dan *GAT*) serta model *baseline XGBoost*.

Tabel 3.2: Hyperparameter eksperimen

Hyperparameter	GraphSAGE	GAT	XGBoost
Learning Rate	5×10^{-3}	5×10^{-3}	0,05
Epoch / Estimator	60	60	500
Hidden Channels	128	64	—
Attention Heads	—	4	—
Dropout Rate	0,3	0,3	—
Subsample	—	—	0,9
Max Depth	—	—	6
Weight Decay	1×10^{-4}	1×10^{-4}	—
Optimizer	Adam	Adam	—
Scheduler	ReduceLROnPlateau	ReduceLROnPlateau	—
Loss Function	MSE pada $\log(\text{harga} + 1)$	MSE pada $\log(\text{harga} + 1)$	MSE
Random Seed	42	42	42
<i>Ekstraksi Fitur Teksual (Semua Model)</i>			
TF-IDF Max Features	50.000	50.000	50.000
TF-IDF <i>n</i> -gram	(1, 2)	(1, 2)	(1, 2)
SVD Components	128	128	—

Eksperimen dijalankan dengan single random seed (42) sehingga standard deviation tidak dilaporkan. Model TF-IDF + Ridge menggunakan $\alpha = 5,0$ dengan *sublinear tf* aktif. Pada model GNN, fitur node *product* dibangun dari gabungan representasi TF-IDF yang direduksi dengan Truncated SVD (128 komponen) bersama fitur tabular (*item_condition_id*, *shipping*). Node *brand* dan *category* menggunakan *embedding* internal berukuran *hidden_channels*. Gradien di-*clip* dengan *max_norm*=1,0 untuk menstabilkan pelatihan, dan model terbaik disimpan berdasarkan *validation loss* terendah.

3.3 Metrik Evaluasi

Untuk mengukur performa prediksi dan tingkat akurasi dari masing-masing model eksperimen, digunakan tiga metrik evaluasi standar regresi, yaitu *Root Mean Squared Logarithmic Error* (RMSLE), *Root Mean Squared Error* (RMSE), dan *Mean Absolute Error* (MAE). RMSLE bertindak sebagai metrik evaluasi utama dalam penelitian ini karena fungsi objektif pelatihan beroperasi pada skala logaritmik, sekaligus berguna untuk meminimalkan dampak kesalahan prediksi proporsional antara barang murah

dan barang mahal. Formulasi matematis untuk masing-masing metrik dijabarkan sebagai berikut:

$$\text{RMSLE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (\log_e(\hat{y}_i + 1) - \log_e(y_i + 1))^2} \quad (3.1)$$

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (\hat{p}_i - p_i)^2} \quad (3.2)$$

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |\hat{p}_i - p_i| \quad (3.3)$$

Di mana N menyatakan jumlah total sampel pengujian, y_i adalah nilai harga asli, dan $\hat{y}_i$ merupakan nilai harga yang diprediksi oleh model dalam skala logaritmik. Pada perhitungan RMSE dan MAE, variabel harga dikembalikan terlebih dahulu ke dalam skala nominal mata uang asli (USD) menggunakan transformasi balik (*inverse log transformation*) yang didefinisikan sebagai $p_i = e^{y_i} - 1$ dan $\hat{p}_i = e^{\hat{y}_i} - 1$. Evaluasi model terbaik didasarkan pada perolehan nilai indeks kesalahan yang paling minimum di antara seluruh model pembanding pada data pengujian (*test set*).

3.4 Hasil Kuantitatif

Tabel 3.3 menyajikan perbandingan performa model *baseline* terbaik (TF-IDF + Ridge) dan model yang diusulkan terbaik (GraphSAGE) berdasarkan metrik RMSLE pada ketiga subset data.

Tabel 3.3: Hasil kuantitatif model

Konfigurasi	Train	Val	Test
TF-IDF + Ridge (Baseline)	0,5212	0,5562	0,5543
GraphSAGE (Proposed)	0,8288	0,6260	0,6464

Nilai RMSLE TF-IDF + Ridge dihitung langsung pada skala harga nominal, sedangkan nilai Train dan Val GraphSAGE dikonversi dari MSE pada $\log(\text{harga} + 1)$ menggunakan $\text{RMSLE} = \sqrt{\text{MSE}}$ sesuai dengan fungsi objektif pelatihan model.

3.5 Analisis Hyperparameter Tuning


Penelitian ini tidak menerapkan pencarian hyperparameter secara otomatis seperti *grid search*, *random search*, maupun *Bayesian optimization*, mengingat keterbatasan sumber daya komputasi pada lingkungan *Google Colab*. Sebagai gantinya, hyperparameter ditentukan secara manual melalui eksperimen bertahap berdasarkan praktik terbaik yang lazim digunakan pada arsitektur GNN serupa.

Analisis sensitivitas dilakukan secara kualitatif terhadap tiga hyperparameter kunci, yaitu *hidden channels*, *learning rate*, dan *dropout rate*. Ukuran *hidden channels* GraphSAGE ditetapkan sebesar 128

setelah nilai 64 menghasilkan kapasitas representasi yang kurang memadai, sedangkan GAT menggunakan 64 dengan 4 *attention heads* sehingga dimensi efektif per *head* tetap sebesar 16. *Learning rate* 5×10^{-3} dipilih karena nilai yang lebih besar (10^{-2}) menyebabkan *val loss* berfluktuasi, sementara nilai yang lebih kecil (10^{-3}) memperlambat konvergensi secara signifikan dalam 60 epoch. *Dropout rate* 0,3 diterapkan pada seluruh lapisan untuk mencegah *overfitting* tanpa mengorbankan kapasitas model secara berlebihan.

Mekanisme *early stopping* implisit diterapkan melalui penyimpanan bobot model terbaik berdasarkan *validation loss* terendah selama pelatihan, dengan scheduler *ReduceLROnPlateau* yang menurunkan *learning rate* sebesar faktor 0,5 apabila *validation loss* tidak membaik selama 5 epoch berturut-turut.

Dikarenakan keterbatasan komputasi, grafik metrik vs. hyperparameter tidak dapat dihasilkan secara sistematis. Kurva konvergensi pada Gambar 3.1 digunakan sebagai dokumentasi alternatif proses pelatihan.



Gambar 3.1: Kurva konvergensi pelatihan GraphSAGE dan GAT

Kedua model menunjukkan penurunan loss yang tajam pada epoch-epoch awal dan mulai stabil setelah epoch ke-20. GraphSAGE mencapai *val loss* terbaik sebesar 0,3919 pada epoch ke-60, sedangkan GAT mencapai 0,4602. Celah antara *train loss* dan *val loss* yang relatif kecil mengindikasikan tidak terjadi *overfitting* yang signifikan pada kedua model, sehingga konfigurasi hyperparameter yang dipilih dinilai sudah memadai untuk tahap eksperimen ini.

3.6 Hasil Kualitatif & Error Analysis

Pada bagian ini, dilakukan analisis kualitatif dan *error analysis* terhadap hasil prediksi harga barang bekas pada aplikasi **SecondPrice** menggunakan empat arsitektur model yang dikembangkan: GraphSAGE, GAT, TF-IDF + Ridge, dan XGBoost. Analisis ini bertujuan untuk mengidentifikasi skenario di mana model memberikan prediksi yang akurat (benar) serta menganalisis minimal 3 kasus anomali atau kesalahan (*error*) prediksi guna merumuskan hipotesis penyebab kegagalan dan langkah mitigasinya.

Berdasarkan pengujian interaktif pada antarmuka pengguna, berikut adalah rincian dari tiga kasus uji yang menunjukkan karakteristik performa dan kelemahan masing-masing model:

1. Kasus 1: Prediksi Konsisten pada Kondisi Ideal (Kondisi Barang: Baik)

SecondPrice
Prediksi harga barang bekas dengan Graph Neural Network

Detail Produk

Nama Produk *
Sepatu

Merek (Brand)
Nike

Kategori
Women/Shoes/Athletic

Kondisi Barang — Baik
1 — Baru 5 — Buruk

Siapa yang bayar ongkir?
Pembeli Perjual (inkl. harga)

Deskripsi Produk
Masih mau yang bagus dan belum lecet

Prediksi Harga

Rekomendasi Harga Jual
Median dari 4 model (robust, tidak sensitif outlier)
\$23.24
Rp 360.220

Rincian per model

Model	Harga
GraphSAGE (GNN)	\$20.92 Rp 324.260
GAT (GNN)	\$11.50 Rp 178.250
TF-IDF + Ridge (Baseline)	\$25.55 Rp 396.025
XGBoost (Baseline)	\$27.09 Rp 419.895

Harga dalam USD & IDR (kurs: 1 USD = Rp 15.500) · Model: GraphSAGE, GAT, TF-IDF+Ridge, XGBoost · Hanya estimasi.

Gambar 3.2: Uji AI melalui Website (Kasus 1)

- **Input:** Nama Produk: “Sepatu”, Merek: “Nike”, Kategori: Women/Shoes/Athletic, Kondisi Barang: **Baik** (Skala 3), Deskripsi: “Masih mau yang bagus dan belum lecet”.
- **Hasil Prediksi:** Rekomendasi Harga Jual (Median): **\$23.24** (Rp 360.220).
- **Rincian Model:** GraphSAGE (\$20.92), GAT (\$11.50), TF-IDF + Ridge (\$25.55), XGBoost (\$27.09 - Terpilih sebagai Terbaik).
- **Analisis:** Pada kondisi parameter yang sinkron dan valid, model *baseline* berbasis pohon (XGBoost) dan teks (TF-IDF + Ridge) memberikan estimasi yang paling mendekati ekspektasi pasar retail barang bekas. Model berbasis graf seperti GraphSAGE mampu menangkap kedekatan *node* produk dalam kluster sepatu atletik wanita dengan baik, sedangkan GAT cenderung memberikan prediksi yang terlalu konservatif (*underpriced*).

2. Kasus 2: Kontradiksi Semantik antara Deskripsi dan Slider Kondisi (Kondisi Barang: Buruk)

SecondPrice ● Backend terhubung
cek ulang

Prediksi harga barang bekas dengan Graph Neural Network

Detail Produk

Nama Produk *

Merek (Brand)

Kategori

Kondisi Barang — **Buruk**

1 — Baru
5 — Buruk

Siapa yang bayar ongkir?

Deskripsi Produk

Masih mau yang bagus dan belum lecet

Rekomendasi Harga Jual

Median dari 4 model (robust, tidak sensitif outlier)

\$14.87

Rp 230.485

Rincian per model

GraphSAGE GNN \$14.92 Rp 231.260	GAT GNN \$11.49 Rp 178.095
TERBAIK TF-IDF + Ridge Baseline \$25.55 Rp 395.025	XGBoost Baseline \$14.82 Rp 228.710

Harga dalam USD & IDR (kurs: 1 USD = Rp 15.500) · Model: GraphSAGE, GAT, TF-IDF+Ridge, XGBoost · Hanya estimasi.

Gambar 3.3: Uji AI melalui Website (Kasus 2)

- **Input:** Parameter sama dengan Kasus 1, namun variabel Kondisi Barang diubah secara ekstrem menjadi **Buruk** (Skala 5), sementara teks deskripsi tetap mempertahankan klaim kualitas tinggi (“*Masih mau yang bagus dan belum lecet*”).
- **Hasil Prediksi:** Rekomendasi Harga Jual (Median): **\$14.87** (Rp 230.485).
- **Rincian Model:** GraphSAGE (\$14.92), GAT (\$11.49), TF-IDF + Ridge (**\$25.55** - Terpilih sebagai Terbaik), XGBoost (\$14.82).
- **Analisis (Kasus Salah/Anomali 1):** Terjadi deviasi perilaku yang signifikan antar model. Model TF-IDF + Ridge sama sekali tidak mengalami perubahan prediksi (\$25.55) karena model *baseline* ini hanya mengekstrak fitur tekstual dan mengabaikan nilai numerik dari *slider* kondisi. Sebaliknya, XGBoost dan GraphSAGE mengalami penurunan harga yang drastis (45%) mengikuti nilai *slider*. Hal ini menandakan adanya **fitur yang dominan secara timpang** pada masing-masing model, sehingga gagal melakukan resolusi konflik ketika input pengguna tidak konsisten.

3. Kasus 3: Kesalahan Input Kategori (*Category Mismatch & Brand Shifting*)

SecondPrice Backend terhubung cek ulang
Prediksi harga barang bekas dengan Graph Neural Network

Detail Produk

Nama Produk *

Merek (Brand)

Kategori

Kondisi Barang — **Buruk**

1 — Baru 5 — Buruk

Sapa yang bayar ongkir?

Pembeli

Deskripsi Produk

Masih mau yang bagus dan belum lecet

Rekomendasi Harga Jual
Median dari 4 model (robust, tidak sensitif outlier)

\$11.06
Rp 171.430

Rincian per model

GraphSAGE GNN	\$12.21 Rp 189.255	GAT GNN	\$9.91 Rp 153.605
TERBAIK TF-IDF + Ridge Baseline	\$21.69 Rp 336.195	XGBoost Baseline	\$5.35 Rp 82.925

Harga dalam USD & IDR (kurs: 1 USD = Rp 15.500) - Model: GraphSAGE, GAT, TF-IDF+Ridge, XGBoost - Hanya estimasi.

Gambar 3.4: Uji AI melalui Website (Kasus 3)

- **Input:** Nama Produk: “Sepatu”, Merek: “Adidas”, Kategori diubah secara keliru menjadi **Women/Dresses/Above Knee**, Kondisi Barang: **Buruk** (Skala 5), Deskripsi: “Masih mau yang bagus dan belum lecet”.
- **Hasil Prediksi:** Rekomendasi Harga Jual (Median): **\$11.06** (Rp 171.430).
- **Rincian Model:** GraphSAGE (\$12.21), GAT (\$9.91), TF-IDF + Ridge (**\$21.69** - Terpilih sebagai Terbaik), XGBoost (**\$5.35**).
- **Analisis (Kasus Salah/Anomali 2 & 3):**
 - **Anomali XGBoost (Kasus Salah 2):** Nilai prediksi anjlok secara ekstrem ke angka \$5.35. Hal ini terjadi karena XGBoost memperlakukan kategori sebagai *categorical feature* yang kaku. Ketika sepatu dimasukkan ke dalam kategori gaun (*dresses*) yang berkategori buruk, representasi pohon keputusan mengarah pada kluster gaun murah, sehingga menghasilkan bias *underpricing* yang parah.
 - **Anomali GNN & TF-IDF (Kasus Salah 3):** TF-IDF + Ridge tetap memprediksi harga tinggi (\$21.69) karena tertolong oleh kata kunci tekstual “Sepatu” dan deskripsi kualitasnya, namun gagal menyadari bahwa secara struktural kategori tersebut salah. Di sisi lain, model berbasis graf (GraphSAGE & GAT) menghasilkan representasi *embedding* yang bias akibat *edge* (sisi) hubungan produk dipaksa terhubung dengan *node* kategori *Dresses*, yang merusak topologi grafik referensi harga antar-barang sejenis.

Dari eksplorasi ketiga kasus kualitatif di atas, dirumuskan beberapa hipotesis utama terkait kelemahan sistem beserta strategi mitigasi yang dapat diimplementasikan:

Tabel 3.4: Matriks Hipotesis Kegagalan dan Strategi Mitigasi

Gejala & Kasus Salah	Hipotesis Penyebab	Mitigasi yang Diusulkan / Dicoba
Kasus 2: TF-IDF mengabaikan <i>slider</i> kondisi; XGBoost/GNN mengabaikan kontradiksi teks deskripsi.	Kurangnya <i>multimodal fusion</i> yang erat antara fitur teks bebas (NLP) dan fitur terstruktur (tabular). Model memproses fitur secara terisolasi.	Mengimplementasikan arsitektur <i>Late Fusion</i> atau <i>Cross-Attention</i> antara <i>embedding</i> teks (BERT/RoBERTa) dengan <i>dense layers</i> fitur tabular sebelum masuk ke regressor utama.
Kasus 3: Prediksi XGBoost rusak akibat <i>human error</i> saat memilih dropdown kategori.	Kerentanan model tabular dan topologi GNN terhadap <i>noisy edges</i> atau kesalahan klasifikasi kategori manual oleh pengguna.	1. Membangun <i>Pre-classifier Model</i> di sisi <i>backend</i> untuk mengotomatisasi pengisian kategori berdasarkan foto atau nama produk. 2. Menerapkan <i>DropEdge</i> atau <i>Graph Attention</i> yang lebih agresif untuk memotong bobot hubungan jika terjadi anomali fitur antar-node.
Semua Kasus: Model GAT secara konsisten menghasilkan nilai <i>underpriced</i> yang jauh dari harga pasar aktual.	Masalah <i>oversmoothing</i> pada GAT atau ketidakmampuan bobot atensi menangkap varians harga properti yang heterogen pada graf renggang.	Melakukan penyetelan ulang <i>hyperparameter</i> (<i>fine-tuning</i> jumlah <i>attention heads</i>), menggunakan <i>residual connections</i> , atau mengganti fungsi agregasi dengan <i>Principal Neighbourhood Aggregation</i> (PNA).

3.7 Pembahasan

Hasil eksperimen menunjukkan bahwa model *baseline* TF-IDF + Ridge secara keseluruhan mengungguli kedua model GNN yang diusulkan pada seluruh metrik evaluasi, dengan RMSLE sebesar 0,5543 dibandingkan GraphSAGE 0,6464 dan GAT 0,6695 pada data pengujian. Temuan ini berlawanan dengan hipotesis awal bahwa struktur graf heterogen akan mampu menangkap relasi antar produk, merek, dan kategori secara lebih efektif dibandingkan pendekatan berbasis teks sederhana.

Terdapat beberapa faktor yang diduga menjadi penyebab utama kesenjangan performa ini. Pertama, TF-IDF + Ridge secara langsung mengeksplorasi seluruh teks nama dan deskripsi produk dengan 50.000 fitur, sedangkan GNN hanya menerima representasi teks yang telah dikompresi menjadi 128 komponen SVD sehingga kehilangan sebagian informasi leksikal yang krusial. Kedua, graf heterogen yang dibangun hanya terdiri dari tiga jenis node (produk, merek, dan kategori) dengan dua jenis relasi, sehingga struktur topologi yang terbentuk belum cukup kaya untuk memberikan sinyal tambahan yang berarti di luar informasi fitur node itu sendiri. Ketiga, pelatihan GNN dilakukan hanya selama 60 epoch pada subset 200.000 data akibat keterbatasan komputasi, sehingga model belum sepenuhnya konvergen pada solusi optimal.

Dibandingkan dengan hasil pada kompetisi Mercari Price Suggestion Challenge, skor RMSLE terbaik di leaderboard publik berada di kisaran 0,39–0,42. Hasil TF-IDF + Ridge pada penelitian ini (RMSLE 0,5543) masih berada di atas rentang tersebut, yang dapat dijelaskan oleh perbedaan ukuran data

pelatihan. Penelitian ini hanya menggunakan 200.000 dari total 1.482.535 baris yang tersedia, serta tidak digunakannya teknik *ensemble* dan *feature engineering* lanjutan yang umum diterapkan pada solusi kompetisi.

Penelitian ini memiliki beberapa keterbatasan yang perlu diakui. Pertama, subset data yang digunakan (200.000 baris) hanya mencakup sekitar 13,5% dari keseluruhan dataset, sehingga model tidak terekspos pada keragaman produk dan merek secara penuh. Kedua, arsitektur GNN yang diimplementasikan dalam eksperimen ini bersifat transductive karena seluruh node produk dimasukkan ke dalam satu graf pelatihan, meskipun GraphSAGE secara teoretis mendukung inferensi inductive apabila diintegrasikan dengan pipeline deployment yang membangun ulang subgraf secara dinamis. Ketiga, hyperparameter tidak dioptimasi secara sistematis sehingga terdapat kemungkinan konfigurasi yang lebih baik belum dieksplorasi. Pada penelitian selanjutnya, penggunaan seluruh data, arsitektur GNN *inductive* yang lebih ekspresif, serta integrasi *pre-trained language model* untuk representasi teks diharapkan dapat meningkatkan performa secara signifikan.

BAB 4

PEMBAGIAN TUGAS & DEKLARASI KONTRIBUSI INDIVIDUAL

4.1 Ibnu Zaky Fauzi – NPM. 2306161870

4.1.1 Komponen yang Dikerjakan

Daftar konkret komponen pengerjaan proyek yang menjadi tanggung jawab penuh saya meliputi:

- Bagian Laporan: Bertanggung jawab penuh terhadap inisialisasi berkas Latex, penyusunan konfigurasi preamble, restrukturisasi hierarki sub-bab laporan agar presisi dengan panduan teknis, pengetikan draf Bab I, integrasi seluruh kontribusi teks dari anggota kelompok, serta pembuatan diagram dan flowchart di laporan.

4.1.2 Pernyataan Penggunaan AI Assistant

- Tool yang dipakai: Claude 4.6 Sonnet
- Untuk bagian apa: Melakukan konversi draf layout tabel dari format konvensional menuju bentuk standar package `tabularx` serta perbaikan sintaks error lingkungan bibliografi Latex serta pembuatan diagram dan flowchart.
- Tingkat ketergantungan: Estimasi $\sim 50\%$ dari total luaran teks laporan berasal dari draf asistensi AI).
- Pernyataan: Saya memahami dan dapat mempertanggungjawabkan setiap baris kode/teks yang saya klaim sebagai bagian saya.

4.2 Nugroho Ulil Abshar – NPM. 2306229310

4.2.1 Komponen yang Dikerjakan

Daftar konkret komponen pengerjaan proyek yang menjadi tanggung jawab penuh saya meliputi:

- Kode/Modul: Perancangan arsitektur core backend , instalasi environment PyTorch Geometric (PyG), penyusunan skema kelas penampung `HeteroData`, pembuatan alur custom training loop , penanganan GPU memory caching, serta mekanisme serialization penyimpanan bobot model (`.pth` files).
- Bagian Analisis: Pendefinisian parameter metadata sistem proyek.
- Bagian Laporan: Penyusunan draf struktur berkas `metadata.json` pada Lampiran A.

4.2.2 Pernyataan Penggunaan AI Assistant

- Tool yang dipakai: Claude 4.6 Sonnet
- Untuk bagian apa: Autocomplete penulisan sintaks tensor casting serta penanganan optimasi alokasi memori cuda vram (`torch.cuda.empty_cache()`).
- Tingkat ketergantungan: Estimasi $\sim 50\%$ output kode pemrograman berasal dari saran generatif AI).
- Pernyataan: Saya memahami dan dapat mempertanggungjawabkan setiap baris kode/teks yang saya klaim sebagai bagian saya.

4.3 Samih Bassam – NPM. 2306250623

4.3.1 Komponen yang Dikerjakan

Daftar konkret komponen pengerjaan proyek yang menjadi tanggung jawab penuh saya meliputi:

- **Kode/Modul:** Pembuatan script komparasi algoritma baseline konvensional (Ridge Regression dan MLP), integrasi komponen visualisasi grafik performa, serta perancangan antarmuka visual aplikasi demo berbasis Gradio Blocks.
- **Bagian Arsitektur:** Perancangan visualisasi diagram alir pemrosesan sistem.
- **Bagian Laporan:** Pengetikan kajian teori komparatif, penuangan rumusan justifikasi ilmiah pemilihan model pada Bab II (Seksi 2.1, 2.2, dan 2.3), serta penyusunan diagram TikZ arsitektur model.

4.3.2 Pernyataan Penggunaan AI Assistant

- **Tool yang dipakai:** Gemini 3.1 Pro
- **Untuk bagian apa:** Membantu memetakan koordinat rendering node TikZ graf agar tidak tumpang tindih, menyusun blok rumusan persamaan matematis (seperti fungsi agregasi model), serta merapikan struktur tabel dan draf teks laporan.
- **Tingkat ketergantungan:** Estimasi $> 50\%$. Konstruksi draf blok kode diagram TikZ, penyusunan rumus matematis, dan pemformatan struktur laporan dibantu secara signifikan oleh asisten AI.
- **Pernyataan:** Saya memahami dan dapat mempertanggungjawabkan setiap baris kode/teks yang saya klaim sebagai bagian saya.

4.4 Maharaka Fadillah – NPM. 2306225520

4.4.1 Komponen yang Dikerjakan

Daftar konkret komponen pengerjaan proyek yang menjadi tanggung jawab penuh saya meliputi:

- Kode/Modul: Eksekusi pembersihan data mentah (data cleaning), perancangan fungsi imputasi nilai kosong (handling missing values), pemisahan hierarki string kategori produk (categorical string tokenization), dan pembagian sampel data training/validation/testing split.

4.4.2 Pernyataan Penggunaan AI Assistant

- Tool yang dipakai: Claude 4.6 Sonnet
- Untuk bagian apa: Pembuatan regular expression (regex) untuk memisahkan string ekspresi kategori berkarakter khusus secara efisien menggunakan package `pandas`.
- Tingkat ketergantungan: Estimasi $\sim 50\%$ bagian rekayasa kode penanganan regex berasal dari saran AI).
- Pernyataan: Saya memahami dan dapat mempertanggungjawabkan setiap baris kode/teks yang saya klaim sebagai bagian saya.

BAB 5

KESIMPULAN & PEKERJAAN LANJUTAN

5.1 Kesimpulan

1. Representasi data transaksional marketplace barang bekas ke dalam bentuk *heterogeneous graph* berhasil dibangun dengan tiga jenis node (produk, merek, dan kategori) serta dua jenis relasi (*has_brand* dan *in_category*), menggunakan fitur tekstual TF-IDF yang direduksi dengan Truncated SVD (128 komponen) sebagai inisialisasi node produk.
2. Arsitektur GraphSAGE dan GAT berhasil diimplementasikan untuk tugas regresi prediksi harga menggunakan framework PyTorch Geometric, dengan *val loss* terbaik masing-masing sebesar 0,3919 dan 0,4602 (MSE pada skala logaritmik) setelah 60 epoch pelatihan.
3. Model *baseline* TF-IDF + Ridge Regression mengungguli kedua model GNN pada seluruh metrik evaluasi, dengan RMSLE 0,5543 dibandingkan GraphSAGE 0,6464 dan GAT 0,6695 pada data pengujian, mengindikasikan bahwa pendekatan berbasis teks langsung lebih efektif pada konfigurasi eksperimen ini.
4. Eksploitasi relasi topologi antar node belum terbukti berkontribusi signifikan dalam mereduksi galat prediksi harga pada skala eksperimen ini, kemungkinan disebabkan oleh keterbatasan kedalaman struktur graf (hanya dua jenis relasi) dan kompresi fitur tekstual yang berlebihan sebelum dimasukkan ke dalam GNN.

5.2 Klaim Bonus Skor

- ✓ B1. Evaluasi Komparatif & Iterasi → bukti pada Subbab 3.4 dan 3.5
- ✓ B3. Analisis Etika, Bias, & Keterbatasan → bukti pada Subbab 3.7

5.3 Pekerjaan Lanjutan (*Future Work*)

1. Melatih ulang model GNN menggunakan seluruh 1.482.535 baris dataset Mercari untuk mengevaluasi apakah peningkatan skala data dapat menutup kesenjangan performa terhadap *baseline*.
2. Mengganti representasi teks TF-IDF + SVD dengan *sentence embedding* dari model pra-terlatih seperti `all-MiniLM-L6-v2` atau `distilbert-base-uncased` untuk menghasilkan inisialisasi fitur node produk yang lebih ekspresif.
3. Memperkaya struktur graf heterogen dengan menambahkan jenis relasi baru, seperti kesamaan harga antar produk (*price similarity edge*) atau relasi ko-kemunculan kata kunci pada deskripsi, sehingga topologi graf mengandung sinyal yang lebih informatif untuk proses *message passing*.

4. Mengevaluasi performa model pada distribusi data *out-of-domain*, misalnya dataset marketplace barang bekas berbahasa Indonesia (Tokopedia / OLX), untuk mengukur kemampuan generalisasi lintas platform.
5. Menerapkan teknik interpretabilitas seperti *GNExplainer* untuk menganalisis kontribusi relatif node merek dan kategori terhadap prediksi harga pada sub-kategori produk tertentu.

Bibliography

- [1] W. L. Hamilton, R. Ying, and J. Leskovec, "Inductive representation learning on large graphs," in *Proceedings of the 31st International Conference on Neural Information Processing Systems (NIPS'17)*, 2017, pp. 1025–1035.
- [2] P. Veličković, G. Cucurull, A. Casanova, A. Romero, P. Liò, and Y. Bengio, "Graph attention networks," in *International Conference on Learning Representations (ICLR)*, 2018.
- [3] L. Zhu, "E-Commerce recommendation algorithm based on graph neural network," *Highlights in Science, Engineering and Technology*, vol. 39, p. 1264, 2023.

LAMPIRAN A

Berkas Metadata Proyek (JSON)

Berikut adalah isi berkas metadata.json proyek kelompok kami:

```
{
  "kode_kelompok": "K17",
  "topik_pilihan": 3,
  "nama_topik": "Graph Neural Network (GNN)",
  "judul_proyek": "SecondPrice: Prediksi Harga Jual Barang Bekas dengan Graph Neural Network",
  "abstrak_singkat": "Proyek ini bertujuan membangun sistem prediksi harga otomatis berbasis Graph Neural Network (GNN) untuk barang bekas di e-commerce. Dengan menggunakan Mercari Price Suggestion Dataset, model merepresentasikan data pasar sebagai graph (produk, merek, kategori) untuk melakukan message passing. Model GNN (GraphSAGE / GAT) akan dievaluasi secara komparatif melawan baseline MLP/XGBoost dan TF-IDF+Ridge Regression untuk memprediksi harga jual wajar tanpa foto.",
  "metode_ai": [
    {
      "nama": "GraphSAGE / GAT",
      "peran": "utama",
      "varian": "GNN untuk prediksi regresi nilai harga berbasis struktur graph pasar",
      "catatan": "Model utama yang memanfaatkan message passing pada entitas produk, merek, dan kategori."
    },
    {
      "nama": "MLP / XGBoost",
      "peran": "baseline",
      "varian": "Prediksi dari fitur tabular biasa tanpa representasi graph",
      "catatan": "Pembanding untuk mengevaluasi efektivitas struktur graph pada GNN."
    }
  ],
  "anggota": [
    {
      "nama": "Ibnu Zaky Fauzi",
      "npm": "2306161870",
      "peran_utama": "Lead Report Integrator & Layout Specialist",
      "konsep_dikuasai_implementasi": [
        "Inisialisasi lingkungan LaTeX, manajemen preamble dokumen tingkat lanjut, dan restrukturisasi hierarki sub-bab laporan",
        "Penyusunan tata letak tabel kompleks menggunakan package tabularx serta visualisasi diagram dan flowchart sistem"
      ],
      "konsep_dikuasai_teoris": [
        "Struktur formal dokumentasi eksperimen AI dan standarisasi sintaks lingkungan bibliografi ilmiah tingkat universitas"
      ]
    }
  ]
}
```

```

    ],
  },
  {
    "nama": "Maharaka Fadillah",
    "npm": "2306225520",
    "peran_utama": "Data Engineer & Preprocessing Specialist",
    "konsep_dikuasai_implementasi": [
      "Eksekusi pipeline data cleaning, penanganan nilai kosong (handling missing values), dan tokenisasi string hierarki kategori",
      "Penerapan regular expression (regex) berbasis library pandas untuk dekomposisi data berkarakter khusus secara efisien"
    ],
    "konsep_dikuasai_teoris": [
      "Prinsip stratifikasi data melalui pembagian sampel training, validation, dan testing split untuk mencegah data leakage"
    ]
  },
  {
    "nama": "Nugroho Ulil Abshar",
    "npm": "2306229310",
    "peran_utama": "Model & Backend Engineer",
    "konsep_dikuasai_implementasi": [
      "Custom training loop dan validation pipeline menggunakan PyTorch",
      "Model serialization (saving & loading .pth weights) untuk kebutuhan deployment"
    ],
    "konsep_dikuasai_teoris": [
      "Mekanisme backpropagation, gradient flow, dan penanganan vanishing gradient pada GNN"
    ]
  },
  {
    "nama": "Samih Bassam",
    "npm": "2306250623",
    "peran_utama": "Evaluator & UI Developer",
    "konsep_dikuasai_implementasi": [
      "Desain antarmuka interaktif multi-input dengan Gradio Blocks",
      "Binding UI input state ke fungsi inferensi backend secara real-time"
    ],
    "konsep_dikuasai_teoris": [
      "Prinsip User Experience (UX) dalam perancangan aplikasi berbasis kecerdasan buatan"
    ]
  }
]
}

```

LAMPIRAN B

Tautan Repositori & Sumber

GitHub repo	https://github.com/nug27/GNN-Kecerdasan_Buatan_Final_Project
Google Colab	https://colab.research.google.com/drive/1WnV0y_X_Qe0QT6tpLDVx6evs7hn6Dhhl?usp=sharing
Sumber dataset	https://www.kaggle.com/datasets/rohitamalnerkar/mercari-dataset

APPENDIX C

Research Participation Consent Form (*Informed Consent*)

REQUIRED to be signed by each group member before report submission. Declining participation (Option C) does not affect academic grades.

C.1 Brief Explanation. *Research:* Development & validation of an *agentic AI* framework for supporting academic oral examinations. *Principal investigator:* [Name of course lecturer], Department of Computer Engineering, Universitas Indonesia. *Co-investigator:* a final-year undergraduate student supervised by the principal investigator. *Contact:* [principal investigator's email]. *Ethics review status:* **under review**. *Context:* data collection is conducted alongside the oral examination of the AI course's final assessment. The oral examination is held as part of the academic assessment regardless of the participant's research-participation choice.

C.2 Data Collected. Final report (PDF) and `metadata.json` file; audio and video recordings of the oral examination; automatic transcripts derived from those recordings; lecturer's *judgment* scores (*ground truth*) and AI system's *judgment* scores (test variable). **Not collected:** biometric data other than voice/face, or personal data beyond what is contained in the academic report.

C.3 Data Management. **Participant names and student IDs (NPMs) will be stored anonymously** — replaced with participant codes (P001, P002, ...) prior to analysis. The code-to-identity mapping table is stored separately, encrypted, and accessed only by the principal investigator. Publications (journal articles, conference papers, theses) will not contain individual identities. Data is stored with encryption on infrastructure managed by the research team; retention is 5 years after the research concludes, after which the data is permanently deleted. Access is limited to the principal and co-investigators; no third party may access without an amendment to this *consent*.

C.4 Participant Rights. (1) The right to decline participation without affecting the course grade. (2) The right to partial participation (e.g. report/metadata may be used, video recording may not). (3) The right to withdraw data at any time **until 30 June 2026** by emailing the principal investigator with the subject [Withdrawal] - [Name] - [NPM]; confirmation of deletion is provided within ≤ 7 working days. After 30 June 2026 the data will have entered the analysis phase and withdrawal becomes impractical. (4) The right to ask questions at any time to the principal investigator. (5) The right to receive a summary of the research findings once they are published (sent to the registered email).

C.5 Individual Consent. Each member completes their personal block on the following pages — one page per member. Tick **exactly one** of the three options (A / B / C), then sign with a wet signature or an *e-signature*.

Individual Consent — Ibnu Zaky Fauzi

Full name : Ibnu Zaky Fauzi
Student ID (NPM) : 2306161870
Email : izaky.thb@gmail.com

I have read Sections C.1–C.4 and understood their contents. I voluntarily choose the following option:

- ☐ **Option A — Full Participation.** I consent to the use of my report, metadata, **and** the audio and video recordings of my oral examination for research purposes.
- ☒ **Option B — Limited Participation.** I consent to the use of my report, metadata, and audio recording, **but I do not consent to the video recording** of my oral examination being used for research. (The video recording will be deleted after the academic assessment is completed.)
- ☐ **Option C — Decline Participation.** I decline to participate in the research. (The academic oral examination proceeds as usual; there is no consequence to the grade.)

Participant's signature



(Ibnu Zaky Fauzi)

Date: 25 Mei 2026

Witness / researcher's signature

(Muhammad Firdaus Syawaludin Lubis,
S.T., M.T., Ph.D.)

Date: 25 Mei 2026

Individual Consent — Samih Bassam

Full name : Samih Bassam
Student ID (NPM) : 2306250623
Email : samihbassam1@gmail.com

I have read Sections C.1–C.4 and understood their contents. I voluntarily choose the following option:

- ☐ **Option A — Full Participation.** I consent to the use of my report, metadata, **and** the audio and video recordings of my oral examination for research purposes.
- ☒ **Option B — Limited Participation.** I consent to the use of my report, metadata, and audio recording, **but I do not consent to the video recording** of my oral examination being used for research. (The video recording will be deleted after the academic assessment is completed.)
- ☐ **Option C — Decline Participation.** I decline to participate in the research. (The academic oral examination proceeds as usual; there is no consequence to the grade.)

Participant's signature



(Samih Bassam)

Date: 25 Mei 2026

Witness / researcher's signature

(Muhammad Firdaus Syawaludin Lubis,
S.T., M.T., Ph.D.)

Date: 25 Mei 2026

Individual Consent — Nugroho Ulil Abshar

Full name : Nugroho Ulil Abshar
Student ID (NPM) : 2306229310
Email : nugrohoulilabshar@gmail.com

I have read Sections C.1–C.4 and understood their contents. I voluntarily choose the following option:

- ☐ **Option A — Full Participation.** I consent to the use of my report, metadata, **and** the audio and video recordings of my oral examination for research purposes.
- ☒ **Option B — Limited Participation.** I consent to the use of my report, metadata, and audio recording, **but I do not consent to the video recording** of my oral examination being used for research. (The video recording will be deleted after the academic assessment is completed.)
- ☐ **Option C — Decline Participation.** I decline to participate in the research. (The academic oral examination proceeds as usual; there is no consequence to the grade.)

Participant's signature



(Nugroho Ulil Abshar)

Date: 25 Mei 2026

Witness / researcher's signature

(Muhammad Firdaus Syawaludin Lubis,
S.T., M.T., Ph.D.)

Date: 25 Mei 2026

Individual Consent — Maharaka Fadhilah

Full name : Maharaka Fadhilah
Student ID (NPM) : 2306225520
Email : maharakafadhilah@gmail.com

I have read Sections C.1–C.4 and understood their contents. I voluntarily choose the following option:

- ☐ **Option A — Full Participation.** I consent to the use of my report, metadata, **and** the audio and video recordings of my oral examination for research purposes.
- ☒ **Option B — Limited Participation.** I consent to the use of my report, metadata, and audio recording, **but I do not consent to the video recording** of my oral examination being used for research. (The video recording will be deleted after the academic assessment is completed.)
- ☐ **Option C — Decline Participation.** I decline to participate in the research. (The academic oral examination proceeds as usual; there is no consequence to the grade.)

Participant's signature



(Maharaka Fadhilah)

Date: 25 Mei 2026

Witness / researcher's signature

(Muhammad Firdaus Syawaludin Lubis,
S.T., M.T., Ph.D.)

Date: 25 Mei 2026